


9 Techniques Clés pour Maîtriser l'IA Moderne

RAG agentique, distillation, GRPO, Mixture-of-Experts, attention avancée, données synthétiques...
un tour d'horizon des méthodes qui redéfinissent la conception, l'entraînement et le déploiement
des LLMs.





RAG : Multimodal et Agentic

Le Retrieval-Augmented Generation combine récupération d'informations externes et génération par un LLM, plutôt que de s'appuyer uniquement sur ses paramètres internes.



RAG Multimodal


Étend la récupération à plusieurs types de données : texte, images, audio, vidéo — pour enrichir une réponse ou répondre à une question visuelle.



Agentic RAG

Le modèle décide lui-même quand chercher, quelles sources interroger, comment combiner les résultats et quand reformuler sa requête.

L'AGENT ORCHESTRE SES SOURCES




Quand chercher ? Quelles sources ? Comment combiner ?



Distillation de Connaissances

Transférer les connaissances d'un grand modèle « professeur » vers un modèle plus petit et plus efficace, le modèle « élève ».





Optimisation de Prompts

Remplacer les essais-erreurs manuels par des algorithmes qui optimisent les prompts comme on optimise les poids d'un réseau de neurones — des frameworks comme DSPy en sont l'illustration.

APPROCHE MANUELLE

« Tu es un expert médical, réponds en 50 mots max... »

Essais-erreurs artisanaux, peu fiables et difficiles à maintenir à grande échelle.



APPROCHE ALGORITHMIQUE (DSPy)

Signature : QuestionMédicale →
RéponseCourte

DSPy teste systématiquement les variations et trouve le prompt optimal à partir des données d'entraînement.

1

Définir un programme modulaire

2

Évaluer avec des métriques

3

Optimiser prompts & paramètres

4

Tester les variations




GRPO — Group Relative Policy Optimization

Algorithme de RL conçu pour améliorer le raisonnement des LLMs (méthode de référence pour DeepSeek et d'autres). Sans modèle critique séparé : les réponses d'un même groupe sont comparées entre elles.

- Pas de fonction de valeur séparée → mémoire réduite
- Compare un groupe de réponses pour une même question
- Calcule l'avantage relatif de chaque réponse
- Favorise les réponses de meilleure qualité


APPLICATIONS : mathématiques · raisonnement logique · cohérence des réponses longues





Mixture-of-Experts (MoE)

Le modèle se compose de plusieurs « experts » spécialisés ; un routeur sélectionne dynamiquement les 2-3 experts les plus pertinents pour chaque token, parmi des dizaines disponibles.



AVANTAGES

- Efficacité computationnelle
- Capacité accrue (milliards de paramètres)
- Spécialisation par domaine

EXEMPLES CÉLÈBRES

Mixtral • DeepSeek-V2/V3 • GPT-4 (supposé)



Chain-of-Agents et Chain-of-RAG


CHAIN-OF-AGENTS (CoA)

Collabore via le langage naturel pour traiter les documents à contexte long, segment par segment.



CHAIN-OF-RETRIEVAL AUGMENTED GENERATION (CoRAG)

Transforme la recherche en processus itératif — idéal pour le raisonnement multi-hop.





Réduction de Mémoire : LightThinker & MLA



LightThinker

Compression du raisonnement étape par étape : les pensées intermédiaires sont condensées pendant l'inférence.

-70%

mémoire

-26%

latence

<1%

perte de précision

PRIMITIVES MÉMOIRE ADAPTATIVES

`commit`

`expand`


`fold`

Ne conserve que l'essentiel du raisonnement, sans perte notable de précision.



Multi-head Latent Attention

Introduit dans DeepSeek-V2 : compresse les vecteurs Key/Value au lieu de les stocker en haute résolution.



Reconstruit l'état utilisable à la demande, seulement quand nécessaire.

RÉSULTAT

Réduction spectaculaire du KV Cache → inférence accélérée sur les longs contextes.



Mécanismes d'Attention Avancés

1

Slim Attention

2x

mémoire en moins

Réduit la mémoire du contexte pour les modèles à Multi-Head Attention. Mathématiquement équivalent à l'attention standard — aucune perte de précision.

2

KArAt

Kolmogorov-Arnold Attention

KAN

opérateurs apprenables

Remplace le softmax fixe par des opérateurs apprenables. Meilleure explicabilité et interactions token-à-token.

3

XAttention

13.5x


accélération

Attention sparse à scoring antidiagonal en blocs. Accélère l'inférence sur les séquences longues sans sacrifier la précision.



Données Synthétiques et Human-in-the-Loop

Générer des données d'entraînement artificielles pour pallier le manque de données réelles, puis les faire valider par des humains pour garantir leur qualité.



TECHNIQUES DE GÉNÉRATION

- Auto-instruction (Q/R depuis documents)
- Évolution d'instructions
- Synthèse multi-agent

RÔLE DU HITL

- Valider les sorties avant intégration
- Corriger les erreurs systématiques
- Fournir des préférences (RLHF, DPO)
- Étiqueter les cas ambigus

CONCLUSION

9 techniques, un même objectif : des systèmes d'IA plus intelligents, plus efficaces, plus fiables.

Technique	Cas d'usage principal	Impact
RAG	Enrichissement contextuel	Précision et fraîcheur des réponses
Distillation	Déploiement efficace	Modèles plus petits et rapides
Prompt Optimization	Automatisation	Prompts optimaux sans essai-erreur
GRPO	Raisonnement RL	Meilleures capacités de raisonnement
MoE	Efficacité à grande échelle	Modèles massifs mais rapides
Chains (CoA / CoRAG)	Tâches complexes	Collaboration et recherche itérative
Memory Reduction	Longs contextes	Inférence économique
Advanced Attention	Optimisation	Vitesse et mémoire optimisées
Synthetic Data + HITL	Entraînement	Données de qualité en quantité