




L'INGÉNIERIE DE L'IA EN 10 COMPÉTENCES

De l'idée à la production avec les Modèles de Fondation




Synthèse structurée basée sur l'ouvrage AI Engineering de Chip Huyen

Du Machine Learning à l'AI Engineering

	Machine Learning Classique			AI Engineering	
L'Approche	Entraînement from scratch		L'Approche	Model-as-a-Service (API)	
Les Tâches	Fermées (Classification, prédiction)		Les Tâches	Ouvertes (Génération de texte, code, agents)	
Le Focus	Ingénierie des features		Le Focus	Ingénierie du contexte et des prompts	
Le Workflow			Le Workflow		


L'ère de l'Échelle : Seules quelques entités peuvent entraîner ces modèles. L'opportunité réside désormais dans leur adaptation.

1. Pensée Produit : Définir le Rôle de l'Humain




Le workflow moderne récompense la vitesse d'itération. Les entreprises déploient d'abord en interne (gestion des connaissances, synthèse) pour limiter les risques avant d'ouvrir des agents externes, décisions en prototypage des agents externes.
La règle d'or : Produit → Données → Modèle.

2. Développement Assisté : Coder à l'Ère de l'Échelle



L'IA abaisse drastiquement la barrière à l'entrée et accélère le prototypage, mais l'expertise humaine reste indispensable pour l'architecture complexe.

3. Ingénierie du Contexte : Le Nouveau Feature Engineering




In-context learning : Permet au modèle d'incorporer de nouvelles informations (Zero-shot vs. Few-shot) sans avoir besoin de ré-entraîner (Finetuning) ses poids.


L'ingénierie du prompt consiste à fournir au modèle l'information exacte dont il a besoin pour activer ses capacités latentes.

4. RAG : La Mémoire Externe du Modèle

RAG (Retrieval-Augmented Generation)	Fine-tuning
Optimise les Faits (Facts) & la mémoire. Idéal pour lutter contre les hallucinations et intégrer des données dynamiques.	Optimise la Forme (Form) & le comportement. Idéal pour imiter un style, une syntaxe, ou un format de sortie spécifique.




5. Multimodalité : Étendre les Sens de l'IA




L'intégration d'images, de vidéos et d'audio dans le pipeline de données permet au RAG et aux Agents de percevoir au-delà du texte.

Un espace latent unifié : Les requêtes textuelles peuvent désormais rechercher des images (et vice versa) en calculant la proximité mathématique dans la base vectorielle.

6. Agents IA : Donner des Mains au Modèle



Flux de Contrôle



L'environnement d'un agent détermine ses outils (ex: recherche web, exécution SQL, envoi d'emails).

7. Évaluation : Le Problème le Plus Difficile de l'IA

Exact Eval (Correctitude Fonctionnelle)

- Exemple : Génération de code (pass@1).
- Vérification binaire : Le code compile-t-il ? Le format JSON est-il valide ?

AI-as-a-Judge (Évaluation Subjective)


Puisque les réponses sont ouvertes, les métriques traditionnelles (BLEU, ROUGE) échouent.

Solution : Un LLM évalue un autre LLM.

Comparative Evaluation : Classement type Chatbot Arena (Scores Elo > 1200). Le modèle compare deux sorties et vote pour la meilleure.

L'ambiguïté des critères exige une définition rigoureuse des guidelines d'évaluation (ex: pertinence, fidélité au contexte).

8. Sélection & Coûts : Le Calculateur de l'Ingénieur



Build vs. Buy : Héberger un modèle open-weight vs utiliser une API propriétaire.


Test-Time Compute & Le Mur du Best-of-N : Échantillonner plusieurs réponses améliore la qualité, mais le modèle se heurte à un mur (la qualité stagne ou dégrade après ~400 échantillons car le vérificateur se fait tromper).

Loi de Chinchilla

Pour un modèle compute-optimal, le volume de données (D) doit être proportionnel à la taille du modèle (N). La formule mathématique :


$$D \approx 20 \times N$$

9. L'Architecture de Production : Orchestrer le Chaos



Les orchestrateurs (comme LangChain ou LlamaIndex) sont le ciment qui connecte ces flux de données asynchrones.

10. Sécurité : Les Garde-Fous de l'IA




Input Guardrails (Avant le modèle) :

- Censure des PII (Données Personnelles).
- Défense contre l'injection de prompts (Jailbreaking).

Output Guardrails (Après le modèle) :

- Vérification des hallucinations et toxicité.
- Sorties Structurées (Grammar Masking) : Forcer le modèle à respecter une grammaire stricte (ex: JSON) via des outils de Constrained Sampling.

La Carte du Territoire : Le Stack AI Engineering



"Le mot-clé post-2020 est l'Échelle."

L'AI Engineering ne consiste plus à savoir comment entraîner un modèle à partir de zéro.

Il s'agit de maîtriser l'art d'assembler, d'évaluer et de sécuriser des modèles de fondation pour résoudre des problèmes concrets.

La technologie est prête.
L'architecture est définie.
À vous de construire.