




Le CRAG (Corrective Retrieval-Augmented Generation) ✨


Ce guide pédagogique et illustré s'adresse aux grands débutants qui souhaitent comprendre comment rendre les systèmes d'Intelligence Artificielle plus fiables en éliminant les hallucinations grâce à l'évaluation et la correction des sources[cite: 4]. 🎉

1. Le Problème du RAG Classique : Le Piège de l'Aveuglement 🙈

Dans un système RAG (Retrieval-Augmented Generation) traditionnel, le processus se déroule en trois étapes linéaires[cite: 4] :

-  **Question** : L'utilisateur pose une question (x)[cite: 4].
-  **Recherche** : Le système récupère des documents (d_1, d_2) dans une base de données vectorielle[cite: 4].
-  **Génération** : L'IA rédige une réponse en se basant sur ces documents[cite: 4].

 **Le piège** : Si les documents trouvés à l'étape 2 sont de mauvaise qualité, hors-sujet ou incomplets, l'IA essaie quand même de répondre avec ce qu'on lui fournit[cite: 4]. Résultat : elle invente des faits, ce que l'on appelle une hallucination[cite: 4]. 🌀



💡 2. La Solution Magique : Le CRAG (Corrective RAG) 🦸

Le Corrective RAG introduit un « juge » intelligent — le Retrieval Evaluator — placé juste après la recherche des documents[cite: 4]. Ce juge analyse la pertinence des sources et oriente dynamiquement le flux vers l'un de trois chemins possibles avant la rédaction finale[cite: 4] :

🗺️ Chemin	📊 Qualité des documents	⚙️ Action principale du pipeline
🟢 Correct [cite: 4]	Bonne et pertinente[cite: 4]	Raffinage des morceaux pertinents (Knowledge Refinement) puis génération directe ($x + k_{in}$)[cite: 4].
🟡 Ambigu [cite: 4]	Partielle ou incertaine[cite: 4]	Combinaison des documents internes récupérables (k_{in}) et d'une recherche externe (ex: web k_{ex})[cite: 4].
🔴 Incorrect [cite: 4]	Mauvaise ou hors-sujet[cite: 4]	Rejet total des documents internes, reformulation de la question et recherche externe complète (k_{ex})[cite: 4].



💎 3. Zoom sur le Raffinage et la Pile Technique 🖥️

Même lorsque les documents sont corrects, le CRAG applique un nettoyage minutieux (découpage en petits morceaux ou strips, filtrage du bruit) pour ne conserver que l'essentiel à transmettre à l'IA[cite: 4]. ✨

🔧 La Stack Technique du Projet (La boîte à outils !) :

- 🐍 **Python** : Le langage de programmation principal[cite: 4].
- 🦜🕸️ **LangChain & LangGraph** : Les frameworks pour orchestrer les flux de travail sous forme de graphes et gérer les embranchements logiques[cite: 4].
- 🐼 **Ollama** : Pour exécuter des modèles de langage en local[cite: 4].
- 😊 **Hugging Face Embeddings** : Pour vectoriser le texte et permettre la recherche par similarité sémantique[cite: 4].
- 🗄️ **Base de données vectorielle** : Pour stocker et retrouver rapidement les documents de référence[cite: 4].

🎯 Synthèse pour débutant

☀️ Le CRAG transforme une IA passive en un agent autonome capable de s'auto-évaluer, de corriger ses erreurs en allant chercher des sources externes si nécessaire, et de produire des réponses solidement ancrées dans la réalité[cite: 4]. Fini les mensonges !