

Comprendre le RAG Multimodal

Architecture (a) Embeddings Dédiés vs Architecture (b) Résumés par LLM & Base Combinée : principes, mécanique interne et critères de choix pour débutants.

1. Qu'est-ce que le RAG Multimodal ?

Le **RAG** (*Retrieval-Augmented Generation* ou Génération Augmentée par Récupération) permet à un Modèle de Langage (LLM) de puiser des faits vérifiés dans une base de documents externes avant de répondre. Alors que le RAG classique ne traite que du texte brut, le **RAG Multimodal** sait ingérer, rechercher et interpréter simultanément des données hétérogènes : *textes, photographies, schémas techniques, graphiques financiers et tableaux scannés*.

Le Défi Central du Multimodal : Comment permettre à une question posée en texte de retrouver fidèlement soit un paragraphe textuel, soit une illustration technique contenue dans un rapport PDF complexe ? Deux approches d'ingénierie dominent aujourd'hui l'industrie.

2. Vue d'Ensemble des Deux Paradigmes

Architecture (a) : Deux Espaces Vectoriels

Les images et les textes sont traités par des modèles d'encodage distincts ou un modèle d'alignement visuel direct (ex: CLIP).

- **Textes** → Modèle de texte → Base Vectorielle Texte.
- **Images** → Modèle d'embeddings multimodal → Base Vectorielle Image.
- **Récupération** : Requêtes distribuées en parallèle sur les deux bases.

Architecture (b) : Multi-Vector Retriever

Un LLM multimodal décrit d'abord chaque image en texte. La recherche s'effectue dans un espace vectoriel textuel unique et unifié.

- **Images** → LLM Vision → Génération d'un résumé textuel riche.
- **Stockage** : Seul le résumé est vectorisé ; l'image brute reste liée par identifiant.
- **Récupération** : L'index textuel pointe vers l'image brute originale.

3. Anatomie Simplifiée d'un Pipeline RAG

Quel que soit le modèle retenu, tout RAG multimodal suit invariablement trois temps :

1. Extraction

Découpage du document source (PDF) pour isoler les fragments de texte et les fichiers images.

2. Indexation

Conversion mathématique en vecteurs de nombres (embeddings) pour calculer la proximité sémantique.

3. Synthèse

Le LLM multimodal final reçoit la question et les pièces extraites pour formuler la réponse vérifiable.

À retenir pour débiter : La différence fondamentale ne réside pas dans le LLM final (qui synthétise la réponse), mais dans *la façon dont l'image est recherchée et reliée à la question de l'utilisateur*.

Architecture (a) : Embeddings Multimodaux & Bases Séparées

L'architecture (a) repose sur une séparation physique des données selon leur modalité d'origine. Le pipeline traite le texte d'un côté et les images de l'autre, en utilisant des modèles d'encodage spécialisés.

Fonctionnement Étape par Étape

1. **Découpage du PDF** : L'outil d'ingestion extrait deux flux distincts : les blocs textuels d'une part, et les fichiers images d'autre part (schémas, photos, logos).
2. **Génération d'Embeddings Multimodaux** : Les images sont converties en vecteurs d'embeddings à l'aide d'un encodeur visuel (ex: *CLIP*, *SigLIP*, *Google Multimodal Embeddings*). Les textes sont convertis par un encodeur textuel.
3. **Double Base Vectorielle** : Deux index séparés sont alimentés : une *Base de Vecteurs Texte* et une *Base de Vecteurs Image*.
4. **Double Requête & Interrogation** : Lorsque l'utilisateur soumet sa question, le système interroge simultanément les deux bases vectorielles.
5. **Synthèse Multimodale** : Les passages textuels les plus pertinents et les images candidates sont assemblés dans le prompt final soumis au LLM Multimodal.

Avantages et Limites de l'Architecture (a)


Points Forts (Forces)

- **Rapidité d'Ingestion** : Pas d'appel à un LLM coûteux pour chaque image lors de l'indexation.
- **Coût d'ingestion réduit** : Moins de tokens LLM consommés en amont.
- **Recherche visuelle naturelle** : Efficace pour trouver des photos d'objets, des logos, des paysages ou des motifs esthétiques.

Limites & Pièges

- **Perte sur les schémas denses** : CLIP et les modèles similaires peinent à lire les chiffres fins dans un graphique ou un diagramme UML.
- **Calibration des scores** : Difficile d'équilibrer le score de similarité du texte avec celui de l'image (comment savoir si une image à 0.72 est plus pertinente qu'un texte à 0.68 ?).
- **Maintenance de deux index** : Double infrastructure de bases vectorielles.

Schéma de Flux : Architecture (a)



En résumé : L'Architecture (a) brille lorsqu'on recherche des images par concept visuel ("trouve une photo de valve rouillée"), mais s'essouffle sur la lecture sémantique fine de schémas techniques complexes.

Architecture (b) : Multi-Vector Retriever & Résumés d'Images

L'architecture (b) adopte une stratégie ingénieuse : **convertir la compréhension de l'image en texte dès l'ingestion** grâce à un LLM Multimodal, tout en conservant l'image originale pour l'étape finale.

La Mécanique Clé : Le « Multi-Vector Retriever »

1. **Extraction Visuelle** : L'image est extraite du document source.
2. **Transcription par LLM Multimodal** : Un modèle de vision (ex: *GPT-4o*, *Claude 3.5 Sonnet*, *Gemini Flash*) analyse l'image et rédige un **résumé exhaustif** : courbes du graphique, colonnes de tableaux, légendes, axes et conclusions.
3. **Indexation Vectorielle Unique** : Seul le *résumé textuel* est transformé en vecteurs et indexé dans une **base vectorielle unique**, aux côtés des textes classiques du document.
4. **Liaison vers l'Image Brute** : Chaque résumé en base conserve un pointeur (clé unique) vers l'image brute haute résolution.
5. **Récupération & Substitution** : Quand la question de l'utilisateur correspond au résumé textuel de l'image, le système ne transmet pas seulement le résumé, mais **injecte l'image brute originale** dans le prompt final du LLM.

Avantages et Limites de l'Architecture (b)


Forces Décisives

- **Précision sémantique maximale** : Capable de raisonner sur les pourcentages exacts d'un camembert ou les étapes d'un organigramme.
- **Base vectorielle unique** : Tous les embeddings sont textuels ; zéro problème d'étalonnage de scores.
- **Recherche hybride facile** : Compatible avec BM25 (mots-clés exacts) et la recherche vectorielle classique.

Contraintes & Limites

- **Coût initial d'ingestion** : Chaque image doit être inspectée par un modèle multimodal lors de l'indexation.
- **Temps d'ingestion** : L'indexation de milliers de pages illustrées prend plus de temps.
- **Biais du résumé** : Si le LLM ignore un infime détail visuel lors du résumé, ce détail ne sera pas trouvable lors de la recherche.

Schéma de Flux : Architecture (b)



Comparatif Détaillé, Cas d'Usage & Guide de Choix

Tableau Récapitulatif Comparatif

Critères	Architecture (a) : Embeddings Dédiés	Architecture (b) : Résumés & Multi-Vector
Espace Vectoriel	Double (1 base image + 1 base texte)	Unique (tous les vecteurs sont textuels)
Performance Graphiques & Schémas	Moyenne à faible (CLIP lit mal les valeurs chiffrées précises)	Excellente (le LLM de vision explicite chiffres, courbes et légendes)
Performance Photos & Catalogue Visuel	Très Forte (reconnaissance immédiate de formes, couleurs, textures)	Bonne mais dépendante de la verbosité du résumé généré
Coût et Vitesse à l'Ingestion	Très rapide et très économique à l'indexation	Plus lent et plus coûteux (1 appel LLM par image indexée)
Complexité d'Architecture	Rapprochement délicat de scores hétérogènes	Simple à intégrer aux moteurs de recherche textuels existants

Cas d'Usage Recommandés par Secteur

Quand choisir l'Architecture (a) ?

- **E-commerce & Mode** : Recherche d'articles similaires à partir d'une photo ("trouve une robe bleue à motifs fleuris").
- **Gestion de Patrimoine Photo / Médias** : Indexation de photothèques, recherche de visages, de paysages ou d'objets du quotidien.
- **Maintenance Terrain Basique** : Identification visuelle rapide de pièces mécaniques standards (vis, joints, connecteurs).

Quand choisir l'Architecture (b) ? (Recommandé)

- **Rapports Financiers & Stratégiques** : Analyse de courbes de résultats, bilans sous forme de diagrammes, benchmarks.
- **Ingénierie & Notices Techniques Aéronautiques / Industrielles** : Schémas électriques, nomenclatures denses, plans cotés.
- **Médecine & Essais Cliniques** : Graphiques d'évolution des biomarqueurs, synthèses statistiques d'études de cas.

Règle de Décision Rapide pour Débutant

La Règle d'Or : Si vos images contiennent des **textes, des diagrammes, des graphiques ou des chiffres** que l'utilisateur va questionner, privilégiez impérativement l'**Architecture (b)**. Si vos images sont des **photographies réelles** dont l'intérêt est purement visuel (objets, décors, vêtements), optez pour l'**Architecture (a)**.

Glossaire : Embeddings Multimodaux

Représentation d'une image et d'un texte dans un même espace mathématique, permettant de comparer directement une phrase avec une image sans passer par une description textuelle.

Glossaire : Multi-Vector Retriever

Mécanisme d'indexation où un élément riche (ex: image ou grand document) est recherché via un résumé intermédiaire, tout en conservant le lien vers l'objet brut d'origine.