

LA STACK DE L'USINE À IA

La métaphore industrielle pour maîtriser l'architecture des systèmes d'intelligence artificielle modernes

LLM = LA MACHINE-OUTIL	• Génère du texte, raisonne, explique et crée du contenu haut niveau. • C'est le moteur de calcul et d'inférence de l'usine, capable de comprendre le langage naturel.	LLM
RAG = MATIÈRES PREMIÈRES	• Trouve la bonne information avant que la machine ne commence à travailler. • Injecte les documents frais et vérifiés de l'entreprise directement dans le contexte du modèle.	RAG
VECTOR DB = L'ENTREPÔT LOGISTIQUE	• Stocke la connaissance sous forme de vecteurs mathématiques denses. • Retrouve l'information par le sens sémantique, et non par simple mot-clé.	VECTOR DB
AI AGENT = LE CHEF D'ATELIER	• Décide de la prochaine action à mener selon l'objectif fixé. • Sélectionne les bons outils et accomplit des tâches complexes en autonomie.	AI AGENT
MCP = PRISE UNIVERSELLE	• Connecte les agents aux outils, applications, APIs, fichiers et bases de données. • Un seul standard ouvert pour des milliers de connexions sans réécriture.	MCP PROTOCOL
GUARDRAILS = SÉCURITÉ & BARRIÈRES	• Définit strictement ce que l'IA a le droit de faire ou ne doit jamais faire. • Protège les utilisateurs, les données sensibles et prévient les dérives.	GUARDRAILS
EVALS = CONTRÔLE QUALITÉ	• Teste rigoureusement si le produit fini est correct, sûr, fidèle et utile. • Mesure en continu la qualité, le coût en tokens, la latence et le taux de succès.	EVALS & QA

 **Vue d'ensemble :** Les 7 pages suivantes détaillent chacun de ces modules avec leurs définitions exactes, architectures illustrées et applications pratiques.

Le LLM : La Machine-Outil de l'Usine

Large Language Model • Moteur de Raisonnement, de Synthèse & de Génération

GPT-4o

Claude 3.5

Llama 3

🎯 L'ANALOGIE INDUSTRIELLE : LE ROBOT D'USINAGE POLYVALENT

Dans une manufacture, la **machine-outil** façonne la matière brute selon les plans qu'on lui transmet. Le **LLM** joue exactement ce rôle : il ne possède pas de mémoire d'entreprise native, mais lorsqu'on lui injecte des instructions claires, il usine le texte, raisonne sur des problèmes complexes et assemble les réponses avec une précision chirurgicale.

ARCHITECTURE FONCTIONNELLE : INFÉRENCE & PRÉDICTION DU PROCHAIN TOKEN

Prompt & Contexte

"Résume le contrat..."

Tokenisation (BPE)

⚙️ Ce que fait la Machine (Forces)

Raisonnement contextuel : Décompose des instructions complexes, synthétise des documents et extrait des entités.

Génération multimodale : Rédige des rapports, écrit du code propre et formate des sorties structurées (JSON/YAML).

Compréhension sémantique : Saisit l'implicite, reformule avec style et traduit entre des dizaines de langages.

⚠️ Ce qu'elle ne peut pas faire seule (Limites)

Connaissance figée : Ses connaissances s'arrêtent à sa date d'entraînement (*knowledge cutoff*).

Hallucinations : En l'absence de faits précis, la machine comble les vides en inventant des données plausibles.

Besoin de matières premières : Sans RAG ni base documentaire, la machine tourne à vide sur vos données privées.

🔑 LE RÔLE CLÉ À RETENIR

Le LLM est le **moteur d'intelligence** de l'usine. Mais une machine sans stock de pièces ni chef d'atelier ne produit rien de valeur : c'est pourquoi elle doit être alimentée par le RAG et pilotée par des Agents.

Le RAG : La Salle des Matières Premières

Retrieval-Augmented Generation • Ancrage Factuel dans Vos Données Métier

🎯 L'ANALOGIE INDUSTRIELLE : L'APPROVISIONNEMENT JUSTE-À-TEMPS

Avant de lancer l'usinage d'une pièce, l'opérateur va chercher les matières premières exactes dans la **réserve**. Le **RAG** fait exactement cela : à chaque question posée, il sélectionne les extraits de documents précis (PDF, Notion, SQL) et les livre sur la table de travail du LLM avant qu'il ne formule sa réponse.

PIPELINE RAG : DE LA QUESTION UTILISATEUR À LA RÉPONSE SOURCÉE

1. Question User

"Quel est le CA 2024 ?"

Vectorisation Requête

📦 Les 3 Étapes Vitales du RAG

- 1. Ingestion & Chunking** : Découpe vos volumineux manuels en segments cohérents (300-800 tokens) avec chevauchement (*overlap*).
- 2. Retrieval & Reranking** : Isole les fragments les plus pertinents et passe un filtre haute précision (*Cross-Encoder*).
- 3. Injection Contextuelle** : Place les extraits au cœur du prompt pour forcer le LLM à s'y référer strictement.

💡 Bénéfices Métier en Entreprise

- Zéro Hallucination** : La machine s'interdit d'inventer : si la donnée manque, elle déclare qu'elle ne sait pas.
- Fraîcheur Immédiate** : Pas besoin de réentraîner le modèle pour ajouter un PDF : il suffit de l'ajouter dans la réserve.
- Traçabilité Juridique** : Chaque phrase générée possède un lien direct vers la page exacte du document source.

🔑 LE RÔLE CLÉ À RETENIR

Le RAG transforme un modèle généraliste en un **expert interne infallible**. Il garantit que l'usine ne fabrique jamais d'information à partir de souvenirs incertains, mais uniquement à partir de pièces certifiées.

Vector DB : L'Entrepôt Logistique Haute Vitesse

Base de Données Vectorielle • Stockage & Recherche par Proximité Sémantique

[Pinecone](#)[Qdrant](#)[pgvector](#)

🎯 L'ANALOGIE INDUSTRIELLE : L'ENTREPÔT ROBOTISÉ À GÉOLOCALISATION

Dans un entrepôt géant d'Amazon, les colis ne sont pas classés par ordre alphabétique, mais par **coordonnées spatiales tridimensionnelles** où les robots filent directement au rayon idoine. La **Vector Database** fonctionne ainsi : chaque idée ou document est converti en coordonnées numériques denses (*embeddings*) pour être retrouvé en quelques millisecondes selon sa ressemblance de sens.

ARCHITECTURE SPATIALE : PROJECTION VECTORIELLE & VOISINAGE SÉMANTIQUE (ANN)

Texte Brute

"Contrat d'embauche"
"Salaire & Avantages"

📊 Pourquoi pas une base SQL classique ?

Compréhension des synonymes : SQL échoue si vous cherchez « voiture » et que le texte dit « automobile ». La Vector DB les place au même endroit.

Tolérance au flou : Recherche sémantique par similarité cosinus (*Cosine Similarity*) même si l'utilisateur fait des fautes ou formule maladroitement.

Indexation ANN : Les graphes type *HNSW* scannent 10 millions d'enregistrements en moins de 10 millisecondes.

🔧 Solutions Majeures du Marché

Bases Dédiées Managées : [Pinecone](#) [Qdrant](#) [Weaviate](#) (conçues sur-mesure pour la vitesse et la scalabilité horizontale).

Extensions SQL : [pgvector](#) pour transformer votre base PostgreSQL existante en base vectorielle sans outil tiers.

Bases Locales Gratuites : [Chroma](#) [FAISS](#) (s'exécutent en mémoire locale pour \$0€\$).

📌 LE RÔLE CLÉ À RETENIR

La Vector DB est l'infrastructure de stockage qui donne au RAG sa **vitesse foudroyante**. C'est l'étagère intelligente où chaque document porte une coordonnée spatiale reflétant exactement son contenu intellectuel.

AI Agent : Le Chef d'Atelier Autonome

Systèmes Agentiques • Planification, Décision, Utilisation d'Outils & Auto-Correction

CrewAI

LangGraph

AutoGPT

🎯 L'ANALOGIE INDUSTRIELLE : LE CONTREMAÎTRE DÉCISIONNAIRE

Le simple robot industriel ne bouge que si on appuie sur un bouton. Le **Chef d'Atelier** (AI Agent), lui, reçoit un objectif global (ex: « Fabrique 500 unités avant ce soir »). Il observe la situation, établit son planning, délègue les tâches, utilise les machines adéquates et corrige les erreurs en cas d'imprévu.

LA BOUCLE COGNITIVE AGENTIQUE : PERCEVOIR → RAISONNER → AGIR → CORRIGER

Objectif Utilisateur

"Planifie la campagne &
envoie les e-mails VIP"

🤖 Les Capacités d'un Système Agentique

Tool Use (Utilisation d'outils) : L'agent ne se contente pas de parler : il déclenche des scripts Python, appelle des webhooks et interroge des API tierces.

Mémoire Long-Terme & Court-Terme : Il garde en mémoire l'historique des actions accomplies pour ne pas répéter une commande échouée.

Architecture Multi-Agents : Plusieurs agents collaborent (ex: un *Agent Rédacteur*, un *Agent Relecteur* et un *Agent Directeur*).

⚡ Frameworks Majeurs

LangGraph : Orchestration basée sur des graphes d'états cycliques avec gestion fine de la persistance et des retours en arrière.

CrewAI : Spécialisé dans la modélisation d'équipes virtuelles d'agents avec rôles, personas et attribution hiérarchique des tâches.

LlamaIndex Workflows : Événementiel et ultra-performant pour combiner agents et pipelines documentaires.

📌 LE RÔLE CLÉ À RETENIR

L'AI Agent transforme l'IA d'un simple générateur passif de texte en un **collaborateur actif** capable de mener un projet complet de bout en bout en prenant des initiatives logiques.


MCP : La Prise Électrique Universelle

Model Context Protocol • Le Standard Ouvert d'Interopérabilité Agents / Outils / Données

🎯 L'ANALOGIE INDUSTRIELLE : LA PRISE MURALE UNIVERSELLE OU L'USB-C DE L'IA

Imaginez devoir fabriquer un câble électrique sur-mesure pour chaque nouvelle machine de l'usine : ce serait un cauchemar de maintenance. Le **MCP (Model Context Protocol)** est la prise standardisée : il permet à n'importe quel Agent d'accéder instantanément à un fichier, une base SQL, GitHub ou Slack via une prise normalisée unique.

ARCHITECTURE MCP : ARCHITECTURE CLIENT / SERVEUR OUVERTE & DÉCOUPLÉE



🔧 Le Problème Régulé par MCP

Fin du développement spaghetti : Avant MCP, chaque entreprise devait réécrire un connecteur d'API différent pour chaque modèle d'IA.

Découverte dynamique : L'agent découvre automatiquement les outils disponibles sur le serveur MCP connecté sans configuration préalable.

Sécurité granulaire : Les serveurs MCP exposent des permissions d'accès strictes (lecture seule, confirmation requise).

💡 Les 3 Primitives Fondamentales

Resources (Données) : Fournit des fichiers, schémas de bases de données ou logs sous forme d'URI lisibles.

Tools (Actions) : Expose des fonctions exécutables (ex: `send\_slack\_message`, `execute\_query`).

Prompts (Gabarits) : Fournit des modèles de contextes optimisés réutilisables par les clients IA.

📌 LE RÔLE CLÉ À RETENIR

Le MCP est le **standard de communication universel** qui met fin aux silos. Il permet de brancher n'importe quel Agent IA sur n'importe quel logiciel d'entreprise en un clic, exactement comme brancher une prise USB-C.

Guardrails : Le Système de Sécurité & Arrêt d'Urgence

Garde-Fous IA • Filtrage des Entrées/Sorties, Confidentialité & Prévention des Dérives

Llama Guard

NeMo Guardrails

PII Masking

🎯 L'ANALOGIE INDUSTRIELLE : LES BARRIÈRES LASER & BOUTONS D'ARRÊT D'URGENCE

Dans une usine robotisée, personne ne s'approche des broyeurs sans passer par un sas de sécurité et des **barrières photoélectriques** qui coupent immédiatement le courant en cas de danger. Les **Guardrails** jouent ce rôle : ils scannent les prompts des utilisateurs et les réponses du LLM pour bloquer fuites de données sensibles et injections toxiques.

ARCHITECTURE BIPOLAIRE : SÉCURITÉ EN ENTRÉE (INPUT GUARD) & SORTIE (OUTPUT GUARD)



🛡️ Protection des Entrées (Input Filters)

Jailbreak & Prompt Injection : Empêche les utilisateurs malveillants de contourner les consignes de base de l'IA (ex: *"Ignore tes instructions précédentes"*).

Anonymisation PII automatique : Détecte et masque les données personnelles (numéros de Sécurité Sociale, CB, adresses) avant envoi au cloud.

Filtrage de périmètre (*Out-of-Scope*) : Refuse de répondre aux questions politiques ou hors sujet métier.

🔒 Protection des Sorties (Output Filters)

Anti-Fuite de secrets : Bloque l'affichage accidentel de mots de passe, jetons API ou secrets industriels dans la réponse.

Contrôle de conformité de format : Valide que la réponse respecte impérativement un schéma JSON strict avant d'être envoyée aux bases de données.

Vérification factuelle (*Self-Check*) : Mesure si la réponse est bien étayée par les documents du RAG.

🔑 LE RÔLE CLÉ À RETENIR

Les Guardrails sont le **bouclier de conformité** de l'entreprise. Ils garantissent que l'IA ne peut jamais être manipulée pour nuire, divulguer des secrets ou engager la responsabilité juridique de la marque.

EVALS : Le Contrôle Qualité & Métriques Industrielles

Évaluations & Benchmarks • Mesure Continue de la Fidélité, de la Latence et du Coût

Ragas

DeepEval

LangSmith

🎯 L'ANALOGIE INDUSTRIELLE : LE BANC D'ÉPREUVE EN BOUT DE CHAÎNE

Aucun constructeur automobile ne livre un véhicule sans tester la résistance des freins et mesurer la consommation d'essence. Les **EVALS** représentent le banc d'essai de l'usine à IA : ils soumettent automatiquement le système à des centaines de tests pour mesurer sa précision, sa vitesse et son coût avant tout déploiement aux utilisateurs.

LA TRIADE D'ÉVALUATION RAG & LA BOUCLE D'AMÉLIORATION CONTINUE

Jeu de Test (Dataset)

500 Questions annotées
+ Réponses de référence

📏 La Triade d'Or de l'Évaluation RAG

Faithfulness (Fidélité) : Vérifie que chaque affirmation de la réponse peut être déduite du contexte documentaire fourni (mesure anti-hallucination).

Answer Relevance (Pertinence) : Évalue si la réponse cible directement le problème sans verbiage inutile.

Context Precision & Recall : Mesure si la recherche documentaire a extrait l'information nécessaire sans apporter de bruit inutile.

📊 Indicateurs Opérationnels de Production

Latence P95 & P99 : Temps de réponse perçu par l'utilisateur (objectif : < 1 à 2 secondes pour une expérience fluide).

Coût unitaire en tokens : Suivi de la consommation financière par utilisateur et détection des requêtes anormales.

Boucle de feedback utilisateur : Analyse des boutons 👍/👎 et tickets de support pour réinjecter les cas d'échec dans le dataset.

📌 LE RÔLE CLÉ À RETENIR

Sans EVALS, l'ingénierie d'IA relève du pur hasard. C'est le **banc d'essai scientifique** qui transforme un bricolage fragile en un produit industriel stable, prévisible et financièrement rentable.