

COURS — ARCHITECTURE DE LA MÉMOIRE DES SYSTÈMES IA

La Connaissance Persistante

Comment organiser des données à jour, unifiées et multi-sources pour qu'un agent puisse s'en souvenir et les interroger intelligemment.



Base Graph



Documents



Relationnel



Séries temporelles



Objets

Cinq familles de stockage, un seul objectif : une mémoire fiable et interrogeable

Pourquoi une mémoire persistante ?

Un agent qui ne se souvient de rien recommence chaque conversation à zéro. La **connaissance persistante** est l'ensemble des données que le système peut conserver et réinterroger dans le temps : documents internes, relations entre entités, historiques de transactions, logs d'événements, fichiers médias.

Le problème n'est pas de stocker — c'est de choisir **le bon type de stockage pour le bon type de donnée**. Une seule base de données ne peut pas tout faire efficacement : une base relationnelle gère mal les relations en réseau complexes, une base vectorielle ne fait pas de transactions ACID, un stockage d'objets ne sait pas requêter du texte.




Figure 1 — Les cinq familles de stockage qui composent une mémoire persistante unifiée

LE PRINCIPE CLÉ

Une architecture de connaissance persistante robuste est **polyglotte** : elle combine plusieurs bases spécialisées derrière une couche d'orchestration (un agent ou un routeur) qui sait où aller chercher chaque type d'information.

Trois qualités recherchées

- **À jour** — les données reflètent l'état actuel du monde, pas un instantané figé.
- **Unifiées** — malgré des formats différents, l'agent peut les relier entre elles (ex. un client, ses achats, ses documents).
- **Multi-sources** — texte, structuré, temporel, binaire coexistent sans être forcés dans un même moule.

🕸 Graphe de connaissance (Knowledge Graph)

Modélise le monde comme des **entités (nœuds)** reliées par des **relations (arêtes)** typées : « Personne A → utilise → Projet X ».

C'est le format idéal quand la valeur de l'information réside **dans les connexions** plutôt que dans les données elles-mêmes : qui travaille avec qui, quel document cite quelle source, quel produit dépend de quel composant.




Figure 2 — Extrait d'un graphe de connaissance : entités et relations typées

Cas d'usage typiques

- Détection de fraude (réseaux de transactions suspectes)
- Recommandation (« les utilisateurs qui ont fait X ont aussi fait Y »)
- Mémoire d'agent conversationnel — relier des faits mentionnés à travers plusieurs sessions
- Cartographie de dépendances techniques ou organisationnelles

⚠ LIMITE

Les bases graph excellent pour les parcours de relations profonds, mais sont moins adaptées aux agrégations massives de type analytique (ex. sommes sur des millions de lignes).

Banque de documents

Stocke du **contenu semi-structuré ou libre** : PDFs, notes, pages wiki, objets JSON. Chaque document est une unité indépendante, souvent indexée pour la recherche plein texte ou sémantique (embeddings).

Cas d'usage

- Base de connaissance interne consultée par un système RAG
- Archivage de contrats, rapports, tickets support
- Configuration flexible où le schéma varie d'un enregistrement à l'autre

Base de données relationnelle

Organise les données en **tables liées par des clés**, avec un schéma strict et des garanties transactionnelles (ACID). C'est la colonne vertébrale des systèmes métier : clients, commandes, produits.




Figure 3 — Schéma relationnel : Clients, Achats et Produits liés par des clés

Cas d'usage

- Suivi des transactions, facturation, inventaire
- Toute donnée où la cohérence et l'intégrité sont critiques



Base de données séries temporelles

Optimisée pour des données **horodatées en flux continu** : logs applicatifs, métriques système, capteurs IoT, événements utilisateur. Chaque point est associé à un instant précis, avec des requêtes centrées sur les tendances et les anomalies.

Cas d'usage

- Monitoring d'infrastructure (CPU, latence, erreurs 404)
- Historique de conversations horodaté pour reconstituer un contexte
- Détection d'anomalies et alerting



Stockage d'objets

Conserve des **fichiers binaires volumineux** — images, audio, vidéo, exports de données — sans structure interne interrogeable. L'accès se fait par identifiant ou métadonnée, pas par contenu.

Cas d'usage

- Pièces jointes, images uploadées, enregistrements audio
- Archivage de gros volumes à faible coût
- Source pour des pipelines de traitement (OCR, transcription, vision)



À RETENIR

Séries temporelles et stockage d'objets se complètent souvent : les métadonnées d'un fichier (quand il a été créé, par qui) vivent en série temporelle ou en base relationnelle, tandis que le fichier lui-même reste dans le stockage d'objets.

Quel stockage choisir ?

Face à une nouvelle donnée, la question n'est pas « quelle est ma base de données préférée » mais « **quelle est la nature de cette information et comment sera-t-elle interrogée** ». L'arbre de décision suivant résume les questions à se poser :




Figure 4 — Arbre de décision pour choisir la bonne famille de stockage

Type de stockage	Force principale	Exemple de requête
 Graph	Parcours de relations multi-sauts	« Quels projets relient A et B ? »
 Documents	Recherche sémantique / plein texte	« Que dit la politique sur les congés ? »
 Relationnel	Cohérence transactionnelle, agrégats	« Chiffre d'affaires du mois dernier ? »
 Séries temporelles	Tendances, anomalies dans le temps	« Pic d'erreurs 404 cette semaine ? »
 Objets	Fichiers binaires volumineux	« Récupère la photo du contrat signé. »

Dans un système agentique, c'est le **planificateur (LLM Planner)** qui décide vers quelle(s) source(s) router chaque sous-question, puis fusionne les résultats en une réponse cohérente.




Figure 5 — Un agent route la requête vers les bons stores puis unifie la réponse



Exercice d'application pratique

MISE EN SITUATION

Vous construisez la mémoire persistante d'un assistant support client. Il doit pouvoir répondre à : « *Le client Dupont a-t-il déjà signalé un bug similaire, quand, et peux-tu me montrer la capture d'écran qu'il avait jointe ?* »

Question : pour chaque partie de la demande, identifiez le type de stockage le plus adapté et justifiez votre choix.

✓ CORRIGÉ

« **A-t-il déjà signalé un bug similaire** » — recherche sémantique dans l'historique des tickets → **Banque de documents** (similarité de contenu), éventuellement reliée à d'autres tickets via une **Base Graph** si l'on veut tracer les liens entre incidents connexes.

« **Quand** » — l'horodatage précis du signalement pointe vers une **Base de données séries temporelles** ou, plus simplement, un champ date en **Base relationnelle** si le volume d'événements reste modéré.

« **La capture d'écran jointe** » — un fichier binaire à récupérer tel quel → **Stockage d'objets**, référencé par un identifiant stocké dans le ticket (base relationnelle ou documents).

L'agent orchestre ces trois appels puis assemble une réponse unique — c'est exactement le rôle du routeur multi-sources vu en Figure 5.