



Les Trois Âges du RAG

Classic · Graph · Agentic :
de la récupération au raisonnement

Cours n°2 · Complément du cours "Induction de compétences"



Table des Matières

4 parties · 13 sections · Du Classic à l'Agentic

0

§0 — Pourquoi récupérer ? Le péché originel du LLM

Le péché originel du LLM · Mémoire externe

Partie I

1

§1 — CLASSIC RAG : « *Retrieves* » — Le bibliothécaire

Pipeline · 5 gestes · Single-hop vs Multi-hop

Partie I

2

§2 — GRAPH RAG : « *Connects* » — Le cartographe

Pipeline · Entités · Local vs Global search

Partie II

3

§3 — AGENTIC RAG : « *Reasons* » — L'enquêteur

Pipeline · Orchestrateur · Auto-évaluation

Partie III

4

§4 — Synthèse : choisir (et combiner)

Tableau comparatif · Arbre de décision

Partie IV

5

§5 — Pont avec le Cours n°1 (mémoire & compétences)

Convergence RAG × Induction compétences

Partie IV

exercices

§exercices — Exercices

6 exercices progressifs du mini au benchmark

Partie IV

references

§references — Références

9 papiers clés de 2020 à 2025

Partie IV



FONDEMENTS

Pourquoi RAG ? · Classic RAG

0

§0

1

§1



§0

Pourquoi récupérer ? Le péché originel du LLM

Le péché originel du LLM · Mémoire externe

****Analogie**** : un LLM seul, c'est un candidat à l'examen ****sans documents**** : il récite ce qu'il a mémorisé au cours (ses poids), il invente quand il a un trou.

LLM SEUL



Connaissance figée au training


Hallucine · Ignore post-cutoff · Pas de source

LLM + RAG

Paramétrique + récupérée

Documents privés, récents, vérifiables

Réponse sourcée



****À retenir**** : RAG = **Retrieval-Augmented Generation** — on ****branche une mémoire externe consultable**** sous le modèle. Toute la suite du cours n'est que l'histoire des ****trois façons de consulter**** cette mémoire.

§1

CLASSIC RAG : « **Retrieves** » — Le bibliothécaire

Pipeline · 5 gestes · Single-hop vs Multi-hop

1.1 Le pipeline (colonne bleue de l'image)

```

Query      "Quelle est la politique de retour ?"
|
▼
EMBED      la requête devient un VECTEUR
|          query → [0.12, -0.87, 0.44, ...]
▼
VECTOR DB  index de tous les chunks du corpus
|          (mêmes vecteurs, calculés offline)
▼
TOP-K CHUNKS  les K fragments les plus proches
|          (similarité cosinus)
▼
LLM        prompt = question + chunks
▼
ANSWER     réponse sourcée par les fragments

```

1.2 Zoom : les 5 gestes techniques

```

CHUNKING      → [ ][ ][ ][ ]
découper le corpus en fragments (256-1024 tokens)

EMBEDDING     "chat assis" → [0.8, 0.1, ...]
sens → géométrie (phrases proches = vecteurs proches)

INDEXATION    Vector DB (FAISS, Chroma, pgvector...)
structure pour recherche de voisins en ms

RETRIEVAL     cosinus(query, chunk) → top-K
K = 3..10 typiquement

GÉNÉRATION    LLM(question ⊕ chunks) → réponse

```

1.3 Force et faiblesse : l'aiguille vs le fil

SINGLE-HOP : "Quelle est la politique de retour ?"
→ 1 chunk contient la réponse → retrieval direct → PARFAIT

MULTI-HOP : "Qui dirige l'entreprise où travaille Marie ?"

chunk A :		chunk B :
"Marie	??	"Le CEO de
travaille	—<—	CompanyX
chez X"		est Paul"

Aucun chunk ne contient la réponse : il faut RELIER A et B.
Le retrieval par similarité échoue : la question ne ressemble
ni à A ni à B pris isolément.

****Bilan** : *Fast, Simple, Single-hop* (bandeau de l'image). Idéal pour FAQ / docs homogènes. Fragile dès que la réponse est **éparpillée** ou qu'on demande une **vue globale** (« résume tout le corpus »).**



STRUCTURATION

Graph RAG · Relations & Multi-hop

2

§2

2.1

§2.1

2.2

§2.2

2.3

§2.3



§2

GRAPH RAG : « *Connects* » — Le cartographe

Pipeline · Entités · Local vs Global search

2.1 Le pipeline (colonne verte de l'image)

```

Query
|
▼
ENTITY EXTRACTION      le LLM lit le corpus et extrait :
|                        [personne:Marie] [org:CompanyX]
|                        [location:Paris] + relations
|
▼
KNOWLEDGE GRAPH         nœuds = entités, arêtes = relations
|
|
▼
CONNECTED CONTEXT       on récupère le VOISINAGE pertinent
|                        (sous-graphe, communauté, résumé)
|
▼
LLM → ANSWER

```

2.2 Mini-graphe : comprendre le multi-hop en un coup d'œil

```

      (Marie)
     /      \
works_at    friend_of
  /          \
(CompanyX)----- (Paul)
  \          /
  located_in
   \        /
   (Paris)

```

Question : "Dans quelle ville travaille l'employeur de Marie ?"


Parcours : Marie —works_at→ CompanyX —located_in→ Paris
 └────────── 2 HOPS : impossible en Classic RAG ───┘

2.3 Deux régimes de retrieval (Microsoft GraphRAG)

LOCAL search	GLOBAL search
"voisinage d'une entité"	"communautés + résumés"
(Marie)→(CompanyX)→(Paris)	cluster {Marie,X,Paris,Paul}
→ questions précises	→ résumé : "Pôle emploi parisien autour de CompanyX..."
	→ questions HOLISTIQUES ("thèmes principaux du corpus")

****Bilan**** : **Relational, Entity-rich, Multi-source*. Bat Classic RAG sur le multi-hop et le sensemaking global.*

****Mais**** : *coût d'extraction élevé, graphe à maintenir, erreurs d'extraction = erreurs de graphe.*



AUTONOMIE

Agentic RAG · Raisonnement & Boucle

3

§3

3.1

§3.1

3.2

§3.2

3.3

§3.3




§3

AGENTIC RAG : « *Reasons* » — L'enquêteur

Pipeline · Orchestrateur · Auto-évaluation

3.1 Le pipeline (colonne violette de l'image)




3.2 L'agent = orchestrateur de sources

Query : "Compare nos ventes 2025 (SQL) avec l'étude de marché (PDF) et l'actualité récente (web)"

Agent : ① plan → 3 sous-requêtes
 ② route → SQL / Vector DB / Search tool
 ③ agrège → synthèse
 ④ juge → "source web trop ancienne" → re-requête

****Point clé de l'image** : la colonne violette **contient** les deux autres — Vector DB *et* Knowledge Graph deviennent des ****outils**** parmi d'autres. Agentic RAG n'est pas un remplaçant : c'est un ****niveau d'organisation supérieur****.**

3.3 La boucle d'auto-évaluation (Self-RAG, Corrective RAG, Reflection)



****Bilan** : *Adaptive, Self-correcting*. Le seul des trois qui ****sait renoncer et recommencer****. ****Mais**** : latence ×3–×10, coût tokens, complexité, et risque d'erreur cumulative si le juge est mauvais (cf. cours n°1, §10 : juge < 50 % de précision → effondrement).**



IV

SYNTHÈSE

Choix · Pont cours n°1 · Exercices

4

§4

4.1

§4.1

4.2

§4.2

5

§5

exercices

§exercices

references

§references



§4


Synthèse : choisir (et combiner)

Tableau comparatif · Arbre de décision

4.1 Le bandeau de l'image, mis à plat

	Classic	Graph	Agentic
Verbe	Retrieves	Connects	Reasons
Profil	Fast, Simple	Relational, Entity-rich	Adaptive, Self-correcting
Sauts	Single-hop	Multi-hop	Multi-hop + multi-source
Latence / coût		faible moyen (index)	élevé (runtime)
Infrastructure	vector DB	+ pipeline d'extraction	+ orchestrateur + outils
Cas type	FAQ, docs	données relationnelles, corpus multi-sources	tâches ouvertes, vérification

4.2 Arbre de décision



§5

Pont avec le Cours n°1 (mémoire & compétences)

Convergence RAG × Induction compétences

CONVERGENCE RAG × COURS N°1

RAG = mémoire externe en **LECTURE seule** (cours n°1, niveau 2 : artefacts externes)

AGENTIC RAG = agent + outils + **BOUCLE DE JUGEMENT**

= Reflection / SkillWeaver appliqués au retrieval

Prochaine étape : agent qui **INDUIT des compétences** de recherche

("skill : interroger le graphe du domaine X")

→ convergence RAG × induction compétences = agent complet

(cours n°1, niveau 2) |

| AGENTIC RAG = agent + outils + BOUCLE DE JUGEMENT |

| = Reflection / SkillWeaver appliqués au retrieval |

| Étape suivante naturelle : que l'agent INDUISE des compétences |

| de recherche ("skill : interroger le graphe du domaine X") |

| → convergence RAG × induction de compétences = agent complet |

Exercices

6 exercices progressifs du mini au benchmark

1. Classic mini

Facile

20 phrases → embeddings (sentence-transformers) + FAISS ; top-3 sur 5 questions.

2. Multi-hop killer

Facile

Montrez une question à 2 hops où votre RAG classic échoue.

3. Graphe mini

Moyen

Extrayez des triplets de 10 phrases, répondez par parcours de graphe.

...

4. Boucle critique

Moyen

Ajoutez un juge (0–5) ; si score < 4 → re-retrieval avec requête reformulée.

5. Router

Difficile

Agent choisit entre vector DB / graphe / web selon la query ; loggez ses choix.

6. Benchmark maison

Expert

Mêmes 10 questions × 3 architectures → précision, latence, coût tokens.

Références

9 papiers clés de 2020 à 2025

Lewis et al. 2020 (RAG) · Edge et al. 2024 (GraphRAG, Microsoft) · Guo et al. 2024 (LightRAG) · Asai et al. 2023 (Self-RAG) · Yan et al. 2024 (Corrective RAG) · Yao et al. 2022 (ReAct) · Shinn et al. 2023 (Reflexion) · Singh et al. 2025 (survey Agentic RAG).