

Les 12 Piliers du RAG en Pratique


Architecture Retrieval-Augmented Generation : concepts clés, schémas d'architecture et analogies concrètes.

Formule Clé : **RAG = Grounded Answers with Your Data** (Réponses factuelles ancrées dans vos données, sans Fine-Tuning).

THÈME 1 / 3 Ingestion, Découpage & Représentation Vectorielle

Pipeline d'encodage de la matière brute

ARCHITECTURE 01 FLUX COMPLET D'INGESTION & INDEXATION VECTORIELLE



1 Indexing

INDEXATION & PIPELINE D'INGESTION

🎯 **L'image mentale :** L'archiviste qui classe méthodiquement les classeurs dès leur arrivée pour que chaque dossier soit repéré en 1 seconde.

- **Ingestion continue :** Parse et nettoie les sources hétérogènes (PDF, Notion, bases relationnelles).
- **Métadonnées (*metadata*) :** Attache à chaque chunk son document parent, auteur, date et droits d'accès (*RBAC*).
- **Mise à jour dynamique :** Capture les modifications (*CDC*) pour éviter la désynchronisation des connaissances.

2

Chunking

DÉCOUPAGE SÉMANTIQUE INTELLIGENT

🎯 **L'image mentale :** Découper un livre en fiches bristol avec une phrase de rappel en haut de chaque carte pour ne jamais briser une idée.

- **Chunk Size optimal :** Segmente les textes en blocs de 300 à 800 tokens selon la granularité désirée.
- **Overlap stratégique :** Conserve 10 à 15% de tokens partagés entre blocs adjacents pour préserver la cohérence.
- **Stratégies avancées :** Découpage récursif basé sur la structure (titres Markdown, sections, tables).

3

Embedding Model

MODÈLE DE PLONGEMENT VECTORIEL

🎯 **L'image mentale :** Le traducteur universel projetant chaque phrase en coordonnées GPS dans un hyperspace sémantique.

- **Vecteurs denses :** Transforme un passage textuel en un tenseur de réels capturant les relations conceptuelles.
- **Espace partagé :** Deux formulations différentes du même concept partagent des vecteurs géométriquement très proches.
- **Modèles de référence :** `text-embedding-3` `BGE-M3` `Cohere Embed v3` .

4

Vector Database

BASE DE DONNÉES VECTORIELLE

🎯 **L'image mentale :** Un radar capable de comparer des millions de cibles spatiales en temps réel pour cibler les plus proches.

- **Indexation ANN :** Utilise des graphes type HNSW pour accélérer les calculs de similarité à grande échelle.
- **Filtrage par métadonnées :** Associe recherche vectorielle et filtres stricts (ex: date > 2024, département RH).
- **Moteurs majeurs :** `Pinecone` `Chroma` `Weaviate` `Qdrant` `pgvector` .

ARCHITECTURE 02 ENTONNOIR DE RECHERCHE : DE LA QUESTION AU CONTEXTE ENRICH

5. Requête Utilisateur

« Qu'est-ce que le RAG ? »
Input Query

5 Retrieval
RÉCUPÉRATION CIBLÉE DES DONNÉES

🎯 **L'image mentale** : Le documentaliste qui parcourt la bibliothèque pour ramener une première pile de documents candidats.

Vector Search : Vectorise la question et interroge la Vector DB pour isoler les k passages sémantiques.

Hybrid Search : Associe sémantique vectorielle et correspondances de mots-clés exacts (*BM25*).

Top-k Candidates : Ramène un groupe élargi (10 à 25 passages) pour ne rater aucun élément critique.

6 Similarity Search
MESURE MATHÉMATIQUE DE PROXIMITÉ

🎯 **L'image mentale** : Le compas géométrique : plus l'angle entre les flèches est fermé, plus les idées convergent.

Cosine Similarity : Évalue l'angle vectoriel (1 = sens identique, 0 = orthogonalité).

Distances alternatives : *Dot Product* (pour vecteurs normalisés) et distance Euclidienne (L_2).

Seuil de coupure : Écarte d'emblée les passages dont le score de similarité est sous le seuil critique.

7 Reranking
RÉORDONNANCEMENT HAUTE PRÉCISION

🎯 **L'image mentale** : Le jury d'admission faisant passer un oral approfondi aux 20 présélectionnés pour ne garder que le Top 3.

Cross-Encoder : Évalue simultanément la paire [Requête + Chunk] avec toute la puissance attentionnelle.

Filtrage du bruit : Élimine les faux positifs lexicaux et réorganise les résultats par pertinence réelle.

Moteurs dédiés : [Cohere Rerank 3](#) [bge-reranker-large](#) .

8 Context Construction
INGÉNIERIE & ASSEMBLAGE DU CONTEXTE

🎯 **L'image mentale** : Le chef qui assemble les meilleurs ingrédients dans l'assiette avant l'envoi en salle.

Gabarit de prompt : Combine rôle système, contraintes de vérité, chunks numérotés et question utilisateur.

Injection de métadonnées : Associe les identifiants de preuve ('[Doc 1: page 4, contrat.pdf]').

Gestion de la fenêtre : Tronque ou compresse pour respecter le budget maximal de tokens du LLM.

ARCHITECTURE 03 GÉNÉRATION ANCRÉE, TRAÇABILITÉ & OBSERVABILITÉ CONTINUE

9. Generation (LLM)

Prompt Enrichi (Context)
GPT-4o / Claude 3.5 / Gemini

9

Generation

GÉNÉRATION ANCRÉE PAR LE LLM

🎯 **L'image mentale** : L'étudiant qui compose son examen avec son recueil documentaire ouvert : il formule avec fluidité sans inventer de faits.

Grounded Answer : Le modèle synthétise la réponse en s'astreignant strictement aux faits fournis.

Condition de rejet : Si la réponse n'est pas dans le contexte, le LLM doit formellement admettre son ignorance.

Préservation du sens : Évite les interpolations et déductions abusives hors contexte.

10

Grounding & Citations

ANCRAGE FACTUEL & TRAÇABILITÉ

🎯 **L'image mentale** : L'article scientifique où chaque affirmation capitale renvoie vers le numéro de page précis de la source.

Preuve documentaire : Associe des balises de citation "[1]" reliées aux chunks sources originaux.

Auditabilité totale : Permet à l'utilisateur de déplier la phrase source pour vérifier le verbatim.

Secteurs critiques : Indispensable en santé, droit, conformité réglementaire et analyse financière.

11

Evaluation

CONTRÔLE QUALITÉ & TRIADE RAG

🎯 **L'image mentale** : Le laboratoire d'essai qui analyse chaque échantillon selon un protocole strict et infalsifiable.

Faithfulness : Vérifie si chaque affirmation est corroborée par le contexte documentaire.

Answer Relevance : Mesure si la réponse répond exactement à la problématique sans dériver.

Context Quality : Mesure le bruit (*Precision*) et les informations manquantes (*Recall*).

Frameworks : [Ragas](#) [TruLens](#) [DeepEval](#) .

12

Monitoring & Opti.

OBSERVABILITÉ & AMÉLIORATION CONTINUE

🎯 **L'image mentale** : Le poste de pilotage surveillant en continu consommation, dérive et météo pour ajuster le vol.

Télémétrie en direct : Trace les latences (*P95/P99 latency*), coûts en tokens et signaux d'usage.

Analyse des échecs : Détecte les silences de recherche (*retrieval miss*) et affine la taille des chunks.

Plateformes : [LangSmith](#) [Arize Phoenix](#) [OpenLIT](#) .

🌟 Synthèse Système : Le RAG en Tant que Chaîne d'Ingénierie Synergique

Un RAG prêt pour la production n'est jamais un script monolithique. C'est l'alignement maîtrisé de **trois architectures complémentaires** : un pipeline d'ingestion robuste (Phase 1), un entonnoir de recherche et réordonnancement sélectif (Phase 2), et une boucle de génération traçable sous surveillance continue (Phase 3).