



SCHÉMA EXPLIQUÉ SIMPLEMENT

RAG Multimodal : deux architectures

Comment rendre les images d'un PDF « cherchables » comme du texte

Technique n°1 du cours — RAG multimodal et agentique

EN UNE PHRASE

Deux façons de rendre les images d'un PDF exploitables par un LLM : les empreinter directement (a), ou les résumer en texte pour tout unifier (b).



Le RAG en 2 phrases

Plutôt que répondre « de tête », le modèle cherche d'abord les passages pertinents dans une base de documents, puis rédige sa réponse en s'appuyant dessus — comme un étudiant qui consulte ses classeurs pendant l'examen.


 **Le problème : les PDF contiennent aussi des images (graphiques, schémas...). Comment les retrouver ?**

LES 5 ÉTAPES COMMUNES AUX DEUX ARCHITECTURES




La seule différence entre (a) et (b) : comment on représente et stocke les images.

Empreintes multimodales et bases vectorielles séparées



Chaque modalité garde sa propre bibliothèque et son propre langage d'empreintes — deux recherches en parallèle.

Résumés d'images et base vectorielle combinée



On « traduit » les images en texte (résumé), ce qui permet de tout ranger dans une seule bibliothèque commune.



Comparaison simple

	(a) Deux bases séparées	(b) Une base combinée
Représentation des images	Empreinte visuelle directe	Résumé texte fait par une IA
Nombre de bases	2 (une par modalité)	1 seule
Recherche	Deux recherches parallèles	Une seule recherche unifiée
✓ Point fort	Information visuelle brute préservée	Plus simple : un seul espace, embeddings texte classiques
⚠ Point faible	Bon modèle multimodal requis ; 2 bases à gérer	Dépend de la qualité du résumé ; détails visuels possibles perdus

Une bibliothèque avec des livres et des tableaux

a

Deux catalogues séparés

Un catalogue de photos des tableaux, un catalogue de fiches de lecture. Le bibliothécaire consulte les deux.

b

Un catalogue unique

Un expert rédige une fiche décrivant chaque tableau ; toutes les fiches (livres + tableaux) rangées ensemble. Fiche trouvée → on va chercher le tableau original.

Le RAG multimodal rend les images « cherchables » comme du texte — en les empreintant directement dans un espace multimodal avec une base dédiée (a), ou en les résumant en texte pour tout unifier dans une base unique (b).